

Analisis Perbandingan Kinerja CNN Standar dan MobileNetV2 Berbasis Transfer Learning untuk Klasifikasi Citra Bunga

Aditya Ananda Kasi, Anggita Ramanda Sephia,
Bonaventura Kevin Andhika Wisesa, Dina Arimaya Putri,

Aditya.ananda.2405356@students.um.ac.id; anggita.ramanda.2405356@students.um.ac.id;
bonaventura.kevin.2405356@students.um.ac.id; dina.arimaya.2405356@students.um.ac.id;

1. Pendahuluan

Bunga adalah alat reproduksi seksual pada tumbuhan berbunga. Ada sekitar 391.000 spesies tanaman vaskular yang saat ini diketahui sains, dimana sekitar 369.000 spesies adalah tanaman berbunga, menurut sebuah laporan oleh Royal Botanic Gardens, Kew, di Inggris[1]. Bunga merupakan salah satu jenis tanaman hias yang memiliki banyak spesies dan tersebar di berbagai wilayah di dunia. Bunga juga mempunyai keunikan masing-masing, karena masing-masing jenis bunga memiliki ukuran, bentuk, maupun warna kelopak yang berbeda antara satu dengan yang lainnya [2].

Namun, beberapa jenis bunga memiliki karakteristik visual yang hampir serupa [3] sehingga sulit dibedakan hanya melalui pengamatan secara langsung. Kesamaan bentuk dan warna membuat proses klasifikasi berdasarkan mata manusia saja menjadi lebih sulit [4]. Selain itu, klasifikasi bunga secara manual membutuhkan keahlian khusus, memerlukan waktu, dan berpotensi menghasilkan keputusan yang tidak konsisten, sehingga pemanfaatan teknologi komputer menjadi solusi yang relevan dalam proses klasifikasi citra bunga [5]. Klasifikasi adalah salah satu teknik dalam membedakan sebuah objek[4]. Mengetahui banyaknya jenis bunga yang telah ditemukan, diperlukan adanya pendekatan digital agar dapat mengklasifikasi berbagai jenis bunga dengan mudah dan cepat.

Kemajuan teknologi tidak dapat dibendung lagi untuk memenuhi setiap kebutuhan manusia[6]. Perkembangan teknologi yang saat ini banyak dimanfaatkan adalah artificial intelligence. Salah satu metode *Artificial Intelligence* untuk pemrosesan citra digital Convolutional Neural Network (CNN) yaitu jenis khusus dari Neural Network satu bidang dari *Deep Learning* yang dapat digunakan untuk klasifikasi citra objek[7]. Keunggulan utama CNN terletak pada kemampuannya untuk mengklasifikasikan citra dengan tingkat akurasi tinggi. Hal ini disebabkan oleh kemampuannya untuk mengurangi jumlah parameter bebas dan menangani deformasi gambar input, seperti translasi, rotasi, dan skala[8].

Beberapa penelitian terkait analisis arsitektur CNN untuk klasifikasi jenis bunga telah banyak dilakukan. Pada tahun 2021, dilakukan penelitian untuk membangun sistem klasifikasi bunga menggunakan pengujian kinerja metode CNN[9]. Meskipun metode CNN standar pada penelitian sebelumnya mampu melakukan klasifikasi citra bunga dengan akurasi sebesar 60%–80%, performa model masih belum optimal untuk proses klasifikasi multiclass, terutama dalam membedakan beberapa jenis bunga yang memiliki kemiripan bentuk dan warna. Metode seperti baseline CNN masih kurang optimal dalam menghasilkan performa klasifikasi yang tinggi[10]. Hal tersebut membuktikan bahwa tidak semua model CNN memiliki kemampuan yang unggul dalam proses klasifikasi citra.

Berdasarkan permasalahan tersebut, penelitian ini mengusulkan penggunaan arsitektur MobileNetv2 pada proses klasifikasi bunga. MobileNetv2 adalah arsitektur jaringan saraf tiruan CNN standar yang menggunakan konvolusi yang dipisahkan secara kedalaman (*depthwise separable convolutions*), untuk membuat jaringan yang ringan yang memungkinkan penggunaan sumber daya komputasi yang efektif[11]. Penggunaan arsitektur ini diharapkan mampu meningkatkan kemampuan model dalam mengekstraksi fitur citra bunga secara lebih optimal serta meningkatkan akurasi klasifikasi dibandingkan metode CNN standar pada penelitian sebelumnya.

2. Metode

2.1 Conceive (Merancang Konsep)

Tujuan penelitian ini adalah untuk membuat sistem klasifikasi bunga secara otomatis dengan menggunakan metode pembelajaran mendalam. Penelitian ini mengadaptasi penelitian sebelumnya yang menggunakan metode Convolutional Neural Network (CNN) standar. Studi sebelumnya menggunakan dataset Oxford17 dan Oxford102 yang masing-masing memiliki akurasi sebesar 84% dan 63%. Berdasarkan evaluasi terhadap penelitian rujukan ditemukan bahwa penggunaan arsitektur CNN standar memiliki keterbatasan dalam menangani dataset dengan jumlah kelas yang besar [12]. Oleh karena itu, penelitian ini melakukan pengembangan dengan menggunakan dataset lain dan membandingkan kinerja CNN standar dengan arsitektur MobileNetv2. Konsep penelitian ini difokuskan pada penerapan Transfer Learning menggunakan arsitektur MobileNetv2 yang telah dioptimasi untuk ekstraksi fitur yang lebih mendalam namun tetap efisien secara komputasi [13].



Gambar 1. Contoh Citra Gambar Bunga

Penelitian ini menggunakan dataset Flower Classification yang terdiri atas 14 kelas bunga, yaitu *astilbe*, *bellflower*, *black-eyed susan*, *calendula*, *california poppy*, *carnation*, *common daisy*, *coreopsis*, *dandelion*, *iris*, *rose*, *sunflower*, *tulip* dan *water lily*. Dataset memiliki struktur awal berupa folder train dan folder val, tetapi pada penelitian ini data dari folder train dibagi menjadi 3 subset. Pembagian dilakukan dengan proporsi 80% train, 10% validation, dan 10% test agar proses pelatihan, validasi, dan pengujian dilakukan pada data yang terpisah. Konfigurasi akhir ini menghasilkan 10,906 citra untuk dilatih, 1,358 citra untuk divalidasi, dan 1.378 citra untuk diuji. bar, sehingga total terdapat 1,360 data gambar. Contoh citra gambar bunga dapat dilihat pada Gambar 1.

2.2 Design (Mendesain)

Sebelum data digunakan dalam proses pelatihan model, dilakukan serangkaian tahapan preprocessing untuk memastikan kualitas dan konsistensi data, yaitu pelabelan data, standarisasi input, augmentasi data, serta pembagian dataset [12].

2.2.1 Pelabelan data

Untuk pelabelan data, setiap subfolder diberi nama yang sesuai dengan kelas bunga yang diwakili seperti yang ditunjukkan pada Gambar 2. Metode ini memungkinkan model untuk membaca label secara otomatis tanpa memerlukan file label khusus.

Studi ini berfokus pada klasifikasi multi-kelas berdasarkan empat belas kategori bunga. Selanjutnya, tujuan klasifikasi diubah menjadi representasi kategorikal (one-hot encoding) untuk memenuhi kebutuhan proses pelatihan model untuk menghitung loss function categorical crossentropy pada proses pelatihan model.



Gambar 2. Contoh Pelabelan Subfolder Citra

2.2.2 Standarisasi Input

Pada tahap ini seluruh citra diubah ukurannya (resize) menjadi 224×224 piksel untuk menyesuaikan standar input pada arsitektur CNN standar dan MobileNetv2 yang digunakan. Setelah proses resize, dilakukan normalisasi nilai piksel dari rentang $[0, 255]$ menjadi $[0, 1]$ dengan membagi setiap nilai piksel menggunakan 255. Normalisasi dilakukan untuk mempercepat proses konvergensi dan meningkatkan stabilitas pelatihan model.

2.2.3 Augmentasi Data

Augmentasi data dilakukan untuk meningkatkan variasi citra pelatihan serta mengurangi risiko overfitting. Teknik augmentasi yang digunakan adalah vertikal flip yang diterapkan secara on-the-fly hanya pada data pelatihan (training set).

Pendekatan augmentasi vertikal mengacu pada penelitian [12]. Selain itu, *data augmentation* terbukti efektif dalam meningkatkan variasi data dan membantu mencegah *overfitting* pada model *deep learning* [14].

2.3 Implementasi

Pada tahap ini diimplementasikan dan dibandingkan dua arsitektur model, yaitu CNN standar sebagai baseline dan MobileNetv2 sebagai model yang diusulkan, untuk mengevaluasi peningkatan performa pada dataset Flower Classification dari Kaggle yang terdiri atas 14 kelas bunga (*astilbe*, *bellflower*, *black_eyed_susan*, *calendula*, *california_poppy*, *carnation*, *common_daisy*, *coreopsis*, *dandelion*, *iris*, *rose*, *sunflower*, *tulip*, *water_lily*). Proses training menggunakan pendekatan supervised learning dengan pembagian data 80:20 untuk training dan validation set. Data augmentation diterapkan yaitu vertikal *flip* untuk mengatasi overfitting.

2.3.1 CNN (Baseline)

Model CNN standar dibangun menggunakan beberapa lapisan utama, yaitu convolution layer, max pooling layer, flatten layer, dan fully connected layer (dense). Lapisan konvolusi berfungsi untuk mengekstraksi fitur-fitur penting dari citra, sedangkan pooling layer digunakan untuk mengurangi dimensi fitur dan mengurangi kompleksitas komputasi [15]. Selanjutnya, hasil ekstraksi fitur diratakan menggunakan flatten layer sebelum diproses pada lapisan dense untuk proses klasifikasi.

Model CNN standar pada penelitian ini dilatih dari awal (from scratch) menggunakan data pelatihan yang telah melalui tahap preprocessing. Fungsi aktivasi yang digunakan pada setiap lapisan konvolusi adalah ReLU (Rectified Linear Unit) karena mampu meningkatkan efisiensi proses pelatihan dan mengurangi masalah vanishing gradient [16]. Pada lapisan output digunakan fungsi aktivasi softmax untuk menghasilkan probabilitas klasifikasi multikelas sebanyak 14 kelas bunga.

Proses pelatihan dilakukan menggunakan optimizer Nadam dan fungsi loss categorical cross-entropy karena sesuai untuk kasus klasifikasi bunga multikelas [17]. Penggunaan CNN standar sebagai model dasar didukung oleh penelitian Pratiwi dan Fauzi [12], yang membuktikan bahwa model ini mampu melakukan klasifikasi citra bunga pada dataset Oxford17 dan Oxford102.

2.3.2 MobileNetv2 (Proposed Model)

Sebagai model utama (proposed model), penelitian ini menggunakan arsitektur MobileNetv2 dengan pendekatan transfer learning. Pada metode ini, bobot awal model diperoleh dari hasil pra-pelatihan (*pre-trained weights*) menggunakan dataset ImageNet, sehingga model telah memiliki kemampuan awal dalam mengenali pola visual umum [13].

MobileNetv2 dipilih karena memiliki efisiensi komputasi yang tinggi melalui penggunaan metode depthwise separable convolution. Teknik ini memisahkan proses konvolusi menjadi dua tahap, yaitu depthwise convolution dan pointwise convolution, sehingga jumlah parameter dan kebutuhan komputasi menjadi lebih ringan dibandingkan CNN standar. Dengan demikian,

MobileNetv2 cocok digunakan pada perangkat dengan sumber daya terbatas namun tetap mampu menghasilkan performa klasifikasi yang baik.

Pada implementasinya, bagian akhir model (top layer) dimodifikasi sesuai kebutuhan penelitian dengan menambahkan *Global Average Pooling Layer*, *Dense Layer*, *Dropout Layer* untuk mengurangi risiko *overfitting* dan *Output Layer* dengan fungsi aktivasi *softmax* sebanyak 14 neuron sesuai jumlah kelas bunga

Selama proses pelatihan digunakan optimizer Nadam dengan fungsi *loss categorical crossentropy*. Selain itu diterapkan mekanisme *early stopping* dan model *checkpoint* untuk menyimpan model terbaik berdasarkan nilai validasi.

Pendekatan *transfer learning* pada MobileNetv2 terbukti mampu meningkatkan performa klasifikasi citra dengan waktu pelatihan yang lebih singkat dibandingkan pelatihan model dari awal (from scratch). Penelitian oleh Andrew G. Howard dkk. menunjukkan bahwa MobileNetv2 memiliki performa yang kompetitif dengan kompleksitas komputasi yang lebih rendah dibandingkan arsitektur CNN.

2.3.3 Konfigurasi Pelatihan Model

Konfigurasi pelatihan yang digunakan pada kedua model disusun berdasarkan optimasi hyperparameter pada penelitian sebelumnya [16], meliputi: Ukuran input citra: 224×224 piksel; Fungsi aktivasi: ReLU dan Softmax; Optimizer: Nadam; Loss function: categorical cross-entropy; Batch size: 32; Epoch: disesuaikan hingga model mencapai konvergensi; Metric evaluasi: Accuracy

Evaluasi model dilakukan menggunakan data validasi dan data uji (test set) untuk mengetahui kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

2.4 Operate (Mengoperasikan dan Mengevaluasi)

Tahap operate merupakan tahap akhir dalam penelitian yang bertujuan untuk mengoperasikan model hasil pelatihan serta melakukan evaluasi terhadap performa model dalam mengklasifikasikan citra bunga. Evaluasi dilakukan untuk mengetahui tingkat akurasi dan kemampuan generalisasi model terhadap data yang belum pernah digunakan selama proses pelatihan.

2.4.1 Proses Pengujian Model

Pada tahap pengujian model CNN standar dan MobileNetv2 yang telah dilatih diuji menggunakan test set yang berisi data citra bunga yang belum pernah dilihat sebelumnya oleh model. Pengujian dilakukan dengan memasukkan citra bunga ke dalam sistem, kemudian model akan memprediksi kelas bunga berdasarkan pola dan fitur yang telah dipelajari selama proses pelatihan.

Hasil prediksi kemudian dibandingkan dengan label asli untuk mengetahui tingkat keberhasilan klasifikasi. Selain menghasilkan prediksi kelas, model juga menghasilkan nilai probabilitas pada setiap kelas menggunakan fungsi aktivasi softmax.

2.4.2 Evaluasi Performa Model

Evaluasi performa dilakukan menggunakan *matrix accuracy* untuk mengukur tingkat ketepatan model dalam melakukan klasifikasi citra bunga. Nilai akurasi dihitung berdasarkan perbandingan jumlah prediksi yang benar terhadap total data pengujian. Rumus perhitungan akurasi ditunjukkan sebagai berikut :

$$Accuracy = \frac{\text{Jumlah Prediksi Benar}}{\text{Total Data Pengujian}} \times 100\%$$

Selain akurasi, proses evaluasi juga memperhatikan nilai loss selama pelatihan dan validasi. Nilai loss digunakan untuk mengetahui seberapa baik model dalam mempelajari pola data. Semakin kecil nilai loss, maka performa model semakin baik.

Untuk memvisualisasikan performa model, digunakan grafik *training accuracy*, *validation accuracy*, *training loss*, dan *validation loss*. Grafik tersebut digunakan untuk mengamati kestabilan proses pelatihan dan mendeteksi kemungkinan terjadinya *overfitting* maupun *underfitting*.

2.4.3 Perbandingan Model

Tahap evaluasi juga dilakukan dengan membandingkan performa antara model CNN standar dan MobileNetv2. Perbandingan dilakukan berdasarkan nilai akurasi, stabilitas pelatihan, waktu pelatihan, efisiensi komputasi, dan kemampuan generalisasi model. Model dengan performa terbaik ditentukan berdasarkan nilai akurasi tertinggi dan kemampuan model dalam mengklasifikasikan data uji secara konsisten.

2.4.4 Analisis Hasil

Hasil evaluasi digunakan untuk menganalisis efektivitas penggunaan arsitektur MobileNetv2 dibandingkan CNN standar pada klasifikasi bunga. Jika model MobileNetv2 menghasilkan akurasi yang lebih tinggi dengan kompleksitas komputasi yang lebih rendah, maka model tersebut dinilai lebih optimal untuk diterapkan pada sistem klasifikasi citra bunga.

Hasil evaluasi ini diharapkan dapat menjadi dasar pengembangan sistem klasifikasi bunga berbasis deep learning yang lebih efisien dan akurat pada penelitian selanjutnya.

3. Hasil dan Pembahasan


3.1 Hasil Implementasi Model

Pada penelitian ini, hasil pengembangan sistem klasifikasi citra bunga dilakukan dengan membandingkan dua model yaitu CNN standar sebagai model baseline dan MobileNetv2 sebagai model pengembangan. Kedua model dilatih dan diuji pada skenario dataset yang sama, sehingga perbandingan performa dapat dilakukan secara lebih objektif. CNN standar digunakan sebagai bentuk reimplementasi pendekatan dasar dari penelitian rujukan, sedangkan MobileNetv2 digunakan sebagai pengembangan berbasis transfer learning.

Model CNN standar dibangun menggunakan tiga blok konvolusi dengan jumlah filter 32, 64, dan 128. Setiap blok konvolusi diikuti oleh max pooling untuk mereduksi dimensi fitur. Selanjutnya, hasil ekstraksi fitur diubah menjadi vektor satu dimensi melalui lapisan *flatten*, kemudian diproses oleh *dense layer* dan *dropout*. Pada lapisan akhir, model menggunakan output layer dengan 14 neuron sesuai jumlah kelas bunga, serta aktivasi *softmax* untuk menghasilkan probabilitas prediksi pada setiap kelas.

3.2 Hasil Pelatihan Model


Pelatihan Baseline CNN dijalankan dengan maksimum 25 pengulangan (*epoch*) namun mekanisme *early stopping* menghentikannya lebih awal pada *epoch* ke-10 karena nilai *val loss* tidak menunjukkan perbaikan selama 5 *epoch* berturut-turut sejak *epoch* ke-5. Model kemudian memulihkan bobot dari *epoch* ke-5 sebagai hasil terbaik dimana *val loss* mencapai titik terendahnya. Sementara itu *val accuracy* hanya bergerak dalam rentang sempit antara 0,6 hingga 0,7 pada separuh akhir pelatihan dan jauh tertinggal dari performa pada data latih.



Gambar 3. Grafik Accuracy dan Loss CNN Standar

Pola perbedaan antara grafik *train* dan *val* yang terlihat pada Gambar 3. merupakan indikasi terjadinya overfitting yang terjadi sejak *epoch* ke-5. Meskipun *train loss* turun terus menerus tetapi *val loss* justru bergerak tidak stabil, menandakan bahwa model semakin baik dalam mengenali data latih, tetapi peningkatan tersebut tidak sepenuhnya terjadi pada data validasi.

Berbeda signifikan, pelatihan MobileNetv2 berlangsung jauh lebih produktif dan stabil hingga epoch ke-15 sebelum akhirnya dihentikan oleh *early stopping*, dengan bobot *val loss* dan *val accuracy* terbaik diambil dari epoch ke-10. Jarak antara train accuracy dan val accuracy relatif lebih kecil, sedangkan nilai loss juga menurun secara lebih konsisten. Hal ini menunjukkan bahwa MobileNetv2 memiliki kemampuan generalisasi yang lebih baik terhadap data validasi. Keunggulan ini terjadi karena MobileNetv2 tidak belajar fitur visual dari awal, melainkan memanfaatkan fitur yang telah dipelajari sebelumnya melalui bobot ImageNet.




Gambar 4. Grafik Accuracy dan Loss MobileNetv2

3.3 Hasil Evaluasi Kinerja Model

Evaluasi kedua model dilakukan menggunakan *test set* yang terpisah dari data pelatihan maupun data validasi, mencakup 1,378 citra dari 14 kelas bunga. Empat metrik digunakan secara bersamaan karena masing-masing mengukur aspek yang berbeda [18] antara lain *accuracy* mengukur proporsi prediksi benar secara keseluruhan, sedangkan *precision*, *recall*, dan *F1-score* digunakan karena ketiganya memberikan gambaran performa klasifikasi yang lebih mendalam dibandingkan *accuracy* saja [19]. *Precision* mengukur ketepatan model dalam mengklaim suatu kelas, *recall* mengukur seberapa lengkap model berhasil mendeteksi seluruh sampel dari setiap kelas, sedangkan *F1-score* merangkum keseimbangan antara *precision* dan *recall* melalui rata-rata harmonik keduanya [19]. Penggunaan *weighted average* dipilih karena jumlah sampel antarkelas tidak sepenuhnya seragam, sehingga kontribusi setiap kelas terhadap metrik keseluruhan disesuaikan secara proporsional.


Tabel 1. Perbandingan Metrik Evaluasi Keseluruhan pada Test Set

Model	Accuracy	Precision	Recall	F1-Score
CNN Dasar	68.58%	69.00%	68.58%	68.12%
MobileNet	90.49%	90.40%	90.49%	90.40%
Selisih	+21.91%	+21.40%	+21.91%	+22.28%



Gambar 5. Grafik Perbandingan *Accuracy*, *Precision*, *Recall*, dan *F1-score*

Tabel 1 dan Gambar 5 menunjukkan bahwa keunggulan MobileNetv2 bersifat menyeluruh dan merata, bukan hanya pada satu atau dua metrik tertentu. Selisih peningkatan berkisar antara 21.40 hingga 22.28 poin persentase di seluruh metrik, yang mengindikasikan bahwa MobileNetv2 tidak sekadar lebih sering memberikan prediksi yang benar, tetapi juga secara konsisten lebih stabil dalam mengenali kelas-kelas bunga secara keseluruhan.



Gambar 6. Grafik *Validation Accuracy per Epoch*

Grafik *validation accuracy per epoch* pada Gambar 6. memperlihatkan perbedaan performa yang jelas antara kedua model. MobileNetv2 sejak awal pelatihan sudah memiliki *validation accuracy* yang tinggi, sedangkan CNN dasar membutuhkan beberapa *epoch* untuk mencapai performa yang lebih stabil. Namun, meskipun CNN dasar mengalami peningkatan, nilai *validation accuracy* tetap berada jauh dibawah MobileNetv2. Hal ini memperkuat bahwa pendekatan *transfer learning* lebih efektif dibandingkan pelatihan CNN dari awal pada skenario dataset penelitian ini.

3.4 Analisis Performa CNN Standar

Pada hasil klasifikasi CNN Standar, beberapa kelas seperti *water lilly*, *sunflower*, *dandelion*, dan *iris* memiliki performa cukup baik dengan F1-score tinggi. Kelas-kelas tersebut cenderung memiliki ciri visual yang cukup kuat seperti warna dominan, bentuk bunga yang khas atau struktur kelopak yang mudah dibedakan.

Namun, CNN Standar mengalami kelemahan dalam beberapa kelas seperti *carnation* dan *calendula* yang memiliki F1-score rendah. Nilai tersebut menunjukkan bahwa model baseline masih kesulitan membedakan kelas-kelas yang memiliki kemiripan visual.

Tabel 2. Perbandingan Metrik CNN Standar

Kelas	Precision	Recall	F1-score	Keterangan
Water Lilly	0.94	0.92	0.93	Sangat Baik
Sunflower	0.92	0.85	0.88	Sangat Baik
Black-eyed Susan	0.84	0.68	0.75	Baik
Calendula	0.47	0.34	0.40	Lemah
Carnation	0.56	0.41	0.47	Lemah

Hasil ini memperlihatkan bahwa CNN Standar mampu mengenali kelas dengan pola visual kuat, tetapi kurang efektif pada kelas yang memiliki karakteristik mirip. Penyebabnya adalah CNN Standar harus mempelajari seluruh fitur dari awal, sehingga model membutuhkan data yang sangat representatif dan variasi yang cukup banyak agar mampu membedakan fitur antar kelas secara lebih akurat.

3.5 Analisis Performa MobileNetv2

MobileNetv2 menunjukkan peningkatan performa pada hampir seluruh kelas seperti *black-eyed susan*, *sunflower* dan *water lilly* dengan nilai F1-score tinggi. Nilai ini menunjukkan bahwa MobileNetv2 mampu mengenali kelas-kelas dengan karakteristik visual khas secara sangat baik.

Tabel 3. Perbandingan Metrik MobileNetv2

Kelas	Precision	Recall	F1-score	Keterangan
Black-eyed Susan	0,94	1,00	0,97	Sangat Baik
Sunflower	0.99	0.95	0.97	Sangat Baik
Water Lilly	0.98	0.97	0.97	Sangat Baik
Calendula	0.78	0.70	0.74	Lemah
Carnation	0.84	0.82	083	Lemah

Meskipun performa MobileNetv2 jauh lebih tinggi, kelas *calendula* dan *carnation* masih menjadi kelas dengan performa relatif paling rendah. Pada kelas *calendula*, *precision* mencapai 0,78, tetapi *recall* hanya 0,70. Artinya, ketika model memprediksi suatu citra sebagai *calendula*, prediksi tersebut cukup sering benar. Namun, dari seluruh citra yang sebenarnya merupakan *calendula*, masih banyak yang tidak berhasil dikenali sebagai *calendula*. Ini menunjukkan bahwa masalah utama pada kelas tersebut adalah banyaknya citra yang terlewat atau tertukar ke kelas lain.

Performa MobileNetv2 yang lebih tinggi menunjukkan bahwa fitur dari ImageNet membantu model mengenali pola visual bunga dengan lebih baik. Berbeda dengan CNN Standar yang harus membangun fitur dari awal, MobileNetv2 sudah memiliki kemampuan awal dalam mengenali pola umum seperti garis, tekstur, warna, kontur, dan bentuk objek. Karena itu, proses pelatihan menjadi lebih efisien dan hasil pengujian menjadi lebih stabil.

3.6 Hasil Keluaran Model

Model klasifikasi yang dikembangkan menghasilkan output berupa label kelas bunga berdasarkan citra input. Pada tahap evaluasi, model menerima citra dari data uji, melakukan preprocessing sesuai arsitektur yang digunakan, kemudian menghasilkan probabilitas prediksi pada 14 kelas. Kelas dengan nilai probabilitas tertinggi dipilih sebagai hasil klasifikasi akhir.

Berdasarkan hasil evaluasi batch, CNN Standar masih menghasilkan kesalahan yang cukup besar pada beberapa kelas, terutama *carnation*, *calendula*, dan *california_poppy*. Sebaliknya, MobileNetv2 menghasilkan output yang lebih akurat dan konsisten pada sebagian besar kelas. Hal ini terlihat dari nilai accuracy dan F1-score MobileNetv2 yang berada di atas 90%.

Tabel 4. Hasil Prediksi Model Manual

Citra Input	Label Aktual	Prediksi Model	Status	Analisis	Citra Input
	Sunflower	Sunflower	Benar	Ciri visual bunga jelas dan mudah dikenali	Sunflower
	Calendula	Coreopsis	Salah	Kemungkinan tertukar karena kemiripan warna atau bentuk kelopak	Calendula
	Water Lilly	Water Lilly	Benar	Bentuk dan warna objek cukup khas	Water Lilly

Berdasarkan hasil prediksi manual pada Tabel 4, model mampu mengklasifikasikan beberapa citra uji secara benar, seperti pada kelas sunflower dan water lily. Dengan demikian, pengujian manual ini memperlihatkan bahwa model telah mampu mengenali citra dengan ciri visual yang kuat, tetapi masih berpotensi mengalami kesalahan pada kelas-kelas yang memiliki kemiripan yang tinggi.

3.7 Pembahasan

Hasil pengujian menunjukkan bahwa MobileNetv2 memberikan peningkatan performa yang signifikan dibandingkan CNN standar. Model CNN standar memperoleh *accuracy* 68.58%, sedangkan MobileNetv2 memperoleh *accuracy* 90.49%. Peningkatan sebesar 21.91% menunjukkan bahwa pengembangan model menggunakan *transfer learning* berhasil meningkatkan kemampuan sistem dalam mengklasifikasikan citra bunga. Peningkatan ini juga konsisten pada *precision*, *recall*, dan F1-score, sehingga dapat disimpulkan bahwa MobileNetv2 tidak hanya unggul dari sisi jumlah prediksi benar, tetapi juga lebih seimbang dalam mengenali kelas-kelas bunga.

Dari sisi performa, hasil penelitian menunjukkan bahwa kelas dengan ciri visual kuat seperti sunflower, *water lily*, *dandelion*, dan *black-eyed susan* lebih mudah dikenali oleh model. Sebaliknya, kelas seperti *calendula* dan *carnation* masih menjadi tantangan karena memiliki kemungkinan kemiripan warna, bentuk kelopak, atau struktur visual dengan kelas lain. Hal ini menunjukkan bahwa kesalahan klasifikasi tidak hanya dipengaruhi oleh arsitektur model, tetapi juga oleh karakteristik visual dataset.

Penelitian ini tidak dapat diklaim secara langsung lebih baik atas penelitian yang dilakukan oleh Pratiwi & Fauzi [12] Penelitian rujukan menggunakan Oxford17 dan Oxford102, sedangkan penelitian ini menggunakan dataset Kaggle dengan 14 kelas bunga. Efektivitas arsitektur tidak bersifat absolut dan tidak bisa menyamaratakan kehebatan satu model untuk semua jenis dataset. Hal ini dibuktikan melalui eksperimen [20] di mana evaluasi perbandingan pada *custom dataset* mendemonstrasikan bahwa performa ekstraksi fitur dari setiap model memberikan karakteristik

visual data secara berbeda-beda. Hasil pengujian pada penelitian ini membuktikan bahwa MobileNetv2 memiliki performa yang secara signifikan lebih unggul dibandingkan CNN standar. Keunggulan ini menegaskan kontribusi penelitian dalam mengembangkan eksperimen perbandingan yang lebih mendalam, di mana MobileNetv2 diintegrasikan sebagai arsitektur pembandingan yang lebih mutakhir terhadap model CNN standar.

Keterbatasan penelitian ini terletak pada beberapa aspek. Pertama, pengujian masih dilakukan pada *data test* dari dataset yang sama, sehingga kemampuan generalisasi terhadap citra dari dunia nyata belum sepenuhnya dapat dipastikan. Kedua, augmentasi yang digunakan masih terbatas pada *vertical flip*, sehingga variasi citra buatan belum terlalu beragam. Ketiga, MobileNetv2 masih digunakan dengan backbone dibekukan, sehingga belum dilakukan *fine-tuning* pada sebagian layer backbone.

4. Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa penggunaan arsitektur MobileNetv2 berbasis transfer learning mampu meningkatkan performa klasifikasi citra bunga secara signifikan dibandingkan CNN standar. Model CNN standar memperoleh *accuracy* sebesar 68.58%, sedangkan MobileNetv2 mencapai *accuracy* sebesar 90.49%. Peningkatan performa juga terlihat pada nilai *precision*, *recall*, dan *F1-score* dengan selisih lebih dari 21% pada seluruh metrik evaluasi. Hasil tersebut menunjukkan bahwa MobileNetv2 memiliki kemampuan generalisasi yang lebih baik dalam mengenali berbagai jenis bunga pada dataset penelitian.

Perbedaan performa kedua model dipengaruhi oleh mekanisme ekstraksi fitur yang digunakan. CNN standar harus mempelajari fitur visual dari awal sehingga lebih rentan mengalami overfitting dan kesulitan membedakan kelas bunga yang memiliki kemiripan visual. Sebaliknya, MobileNetv2 memanfaatkan bobot hasil pre-trained ImageNet sehingga mampu mengenali pola visual umum seperti tekstur, warna, garis, dan bentuk objek secara lebih efektif. Selain itu, penggunaan *depthwise separable convolution* pada MobileNetv2 membuat proses komputasi menjadi lebih efisien tanpa mengurangi kualitas klasifikasi.

Hasil evaluasi juga menunjukkan bahwa kelas bunga dengan ciri visual yang kuat seperti *sunflower*, *water lily*, dan *black-eyed susan* dapat dikenali dengan sangat baik oleh kedua model, terutama MobileNetv2. Namun, beberapa kelas seperti *calendula* dan *carnation* masih memiliki tingkat kesalahan klasifikasi yang relatif lebih tinggi karena adanya kemiripan warna dan bentuk kelopak dengan kelas lain. Hal ini menunjukkan bahwa karakteristik visual dataset turut memengaruhi keberhasilan proses klasifikasi.

Secara keseluruhan, penelitian ini membuktikan bahwa pendekatan transfer learning menggunakan MobileNetv2 lebih optimal dibandingkan CNN standar untuk klasifikasi citra bunga multikelas. Model yang dihasilkan memiliki tingkat akurasi yang tinggi, pelatihan yang lebih stabil, serta kemampuan generalisasi yang lebih baik. Oleh karena itu, MobileNetv2 berpotensi diterapkan pada sistem klasifikasi citra bunga berbasis deep learning yang membutuhkan efisiensi komputasi dan performa klasifikasi yang baik.

Referensi

- [1] H. A. Pratiwi, M. Cahyanti, and M. Lamsani, "IMPLEMENTASI DEEP LEARNING FLOWER SCANNER MENGGUNAKAN METODE CONVOLUTIONAL NEURAL NETWORK," *Sebatik*, vol. 25, no. 1, pp. 124–130, Jun. 2021, doi: 10.46984/sebatik.v25i1.1297.
- [2] I. A. S. P. Adi, "Ragam Rangkaian Bunga sebagai Penghias Lobby Hotel di Kawasan Wisata Ubud, Bali," *Jurnal Bisnis Hospitaliti*, vol. 12, no. 1, pp. 1–13, Jun. 2023, doi: 10.52352/jbh.v12i1.1091.
- [3] W. Shinta Sari and C. Atika Sari, "Klasifikasi Bunga Mawar Menggunakan KNN dan Ekstraksi

- Fitur GLCM dan HSV,” *SKANIKA: Sistem Komputer dan Teknik Informatika*, vol. 5, no. 2, pp. 145–156, 2022.
- [4] Y. A. Suwitono and F. J. Kaunang, “Implementasi Algoritma Convolutional Neural Network (CNN) Untuk Klasifikasi Daun Dengan Metode Data Mining SEMMA Menggunakan Keras,” *Jurnal Komtika (Komputasi dan Informatika)*, vol. 6, no. 2, pp. 109–121, Nov. 2022, doi: 10.31603/komtika.v6i2.8054.
- [5] A. Peryanto, A. Yudhana, and R. Umar, “Convolutional Neural Network and Support Vector Machine in Classification of Flower Images.”
- [6] M. Hafizh, T. Novita, D. Guswandi, H. Syahputra, and L. Mayola, “Implementasi Data Mining Menggunakan Algoritma Fp-Growth Untuk Menganalisa Transaksi Penjualan Ekspor Online,” *Jurnal Teknologi Dan Sistem Informasi Bisnis*, vol. 5, no. 3, Jul. 2023, doi: 10.47233/jteksis.v5i3.847.
- [7] E. Oktafanda, “Klasifikasi Citra Kualitas Bibit dalam Meningkatkan Produksi Kelapa Sawit Menggunakan Metode Convolutional Neural Network (CNN) ,” *Jurnal Informatika Ekonomi Bisnis*, vol. 4, no. 3, pp. 72–77, Aug. 2022, doi: 10.37034/infec.v4i3.143.
- [8] Sandy Andika Maulana, Shabrina Husna Batubara, Tasya Ade Amelia, and Yohanna Permata Putri Pasaribu, “Penerapan Metode CNN (Convolutional Neural Network) Dalam Mengklasifikasi Jenis Ubur-Ubur,” *Jurnal Penelitian Rumpun Ilmu Teknik*, vol. 2, no. 4, pp. 122–130, Dec. 2023, doi: 10.55606/juprit.v2i4.3084.
- [9] A. Munandar and A. Rozi, “Analisis Arsitektur Convolutional Neural Network Untuk Klasifikasi Citra Bunga,” *Jurnal Teknologi Dan Sistem Informasi Bisnis*, vol. 6, no. 3, Jul. 2024, doi: 10.47233/jteksis.v6i3.1413.
- [10] S. Huzzaemah Andzani, Y. Arie Wijaya, A. Faqih, R. Kurniawan, and P. Studi Manajemen Informatika, “PERBANDINGAN TEKNIK OPTIMASI CNN UNTUK KLASIFIKASI GAMBAR SAMPAH BERBASIS DATASET KECIL DAN TIDAK SEIMBANG,” 2025, doi: 10.32485/jcsai.
- [11] J. Wijaya and K. Kusriani, “Classification of Coffee Fruit Ripe Levels from the Tree Using InceptionResnetv2, and MobileNetv2,” *Bitnet: Jurnal Pendidikan Teknologi Informasi*, vol. 10, no. 1, pp. 70–79, Jan. 2025, doi: 10.33084/bitnet.v10i1.9278.
- [12] A. Pratiwi and A. Fauzi, “IMPLEMENTATION OF DEEP LEARNING ON FLOWER CLASSIFICATION USING CNN METHOD,” *Jurnal Teknik Informatika (Jutif)*, vol. 5, no. 2, pp. 487–495, Apr. 2024, doi: 10.52436/1.jutif.2024.5.2.1674.
- [13] K. R. Prilianti, V. V. Oktariyanto, and H. Setiawan, “ORNAMENTAL PLANT IDENTIFICATION SYSTEM USING TRANSFER LEARNING ON CONVOLUTIONAL NEURAL NETWORK,” *Jurnal Teknik Informatika (Jutif)*, vol. 5, no. 4, pp. 1015–1023, Jul. 2024, doi: 10.52436/1.jutif.2024.5.4.1964.
- [14] Sutarti and Fariza Syaqqialloh, “Klasifikasi dan Pengenalan Emosi dari Ekspresi Wajah Menggunakan CNN-BiLSTM dengan Teknik Data Augmentation,” *Decode: Jurnal Pendidikan Teknologi Informasi*, vol. 5, no. 1, pp. 79–91, Mar. 2025, doi: 10.51454/decode.v5i1.1038.
- [15] D. Zahirah, P. Purnawansyah, N. Kurniati, and H. Darwis, “DIGITAL IMAGE CLASSIFICATION OF HERBAL LEAVES USING KNN AND CNN WITH GLCM FEATURES,” *Jurnal Teknik Informatika (Jutif)*, vol. 5, no. 1, pp. 61–67, Jan. 2024, doi: 10.52436/1.jutif.2024.5.1.1162.
- [16] D. A. Wibowo, N. Suciati, and A. Yuniarti, “HYPERPARAMETER OPTIMIZATION OF CONVOLUTIONAL NEURAL NETWORK FOR FLOWER IMAGE CLASSIFICATION USING GRID SEARCH ALGORITHMS,” *Jurnal Teknik Informatika (Jutif)*, vol. 5, no. 1, pp. 313–320, Feb. 2024, doi: 10.52436/1.jutif.2024.5.1.1798.
- [17] Q. Aini, Zulfiandri, R. Firmansyah, and Y. M. Arif, “Applying convolutional neural network and Nadam optimization in flower classification,” *Bulletin of Electrical Engineering and Informatics*, vol. 13, no. 4, pp. 2865–2877, Aug. 2024, doi: 10.11591/eei.v13i4.6203.

- [18] M. Conciatori, A. Valletta, and A. Segalini, “Improving the quality evaluation process of machine learning algorithms applied to landslide time series analysis,” *Comput. Geosci.*, vol. 184, Feb. 2024, doi: 10.1016/j.cageo.2024.105531.
- [19] B. Bozkurt, K. Coskun, and G. Bakal, “Building a challenging medical dataset for comparative evaluation of classifier capabilities,” *Comput. Biol. Med.*, vol. 178, p. 108721, 2024, doi: <https://doi.org/10.1016/j.combiomed.2024.108721>.
- [20] Y. Gulzar, Z. Ünal, T. Kizildeniz, and U. M. Umar, “Deep Learning-Based Classification of Alfalfa Varieties: A Comparative Study Using a Custom Leaf Image Dataset,” *MethodsX*, vol. 13, p. 103051, Nov. 2024, doi: 10.1016/j.mex.2024.103051.

Lampiran

- Link code google collab : https://colab.research.google.com/drive/1Zf_ZZUZaujYlJBib5TezFINX2lDQH0xT?usp=sharing
- Link drive laporan : https://drive.google.com/drive/folders/1sxSNj_kE-3vJ5aOJ3dZsBFyns8JrqJiM?usp=sharing
- Link Dataset : <https://www.kaggle.com/datasets/marquis03/flower-classification>